ITNPBD6 Machine Learning Assignment Spring R/D 2022

Computing and Maths, University of Stirling

Bannockburn Books (BBB) est une chaîne de librairies qui a connu une croissance rapide ces dernières années, car les gens sont devenus frustrés par les détaillants en ligne. Ils souhaitent étendre encore plus leur réseau de magasins. Bien sûr, c'est un processus coûteux et comporte des risques considérables : ouvrir un magasin qui n'est pas rentable coûte de l'argent, mais l'entreprise ne veut pas passer à côté de magasins potentiellement rentables. Le propriétaire de la chaîne, Bill Wallace, aimerait utiliser les performances de ses magasins existants pour prédire quand un nouveau magasin pourrait réussir. C'est là que vous intervenez. BBB a fourni des données décrivant les magasins existants et leurs performances. Les données nous indiquent si chaque magasin s'est bien comporté selon les mesures de l'entreprise dans la colonne "performance".

Votre mission consiste à utiliser des techniques d'apprentissage automatique pour produire un système capable de dire à BBB quand un nouveau magasin est susceptible de réussir.

Vous pouvez utiliser Orange, Python, R ou tout package d'apprentissage automatique de votre choix. Les données du devoir se trouvent dans un fichier *bbb.csv* qui vous est fourni. Un dictionnaire de données est fourni décrivant les colonnes de ce fichier.

Vous pouvez publier des questions générales sur le devoir dans le canal « Questions d'évaluation » de Teams.

Veuillez noter qu'il s'agit d'un travail individuel et non d'un travail de groupe. Voir la section sur l'inconduite scolaire à la fin de ce mémoire pour plus de détails.

Exigence

Vous devez soumettre un rapport décrivant le processus de modélisation que vous avez suivi et vos résultats. Vous devriez essayer de formuler le problème sous la forme d'un cadre CRISP-DM pour mieux faciliter la discussion. Reportez-vous aux étapes CRISP-DM pertinentes à chaque étape de votre rapport. Vous n'avez pas besoin de soumettre de code ou de données. Le rapport vaut 100 points au total et doit couvrir les éléments suivants (avec des pondérations par section comme indiqué) :

Compréhension commerciale [10 %]

Décrivez la tâche qui vous a été confiée : s'agit-il d'un regroupement, d'une classification ou d'une régression ? ; décrivez les données que vous avez reçues et les exigences du système fini, y compris pourquoi l'apprentissage automatique convient à cette tâche. Définissez toute terminologie que vous utiliserez dans le rapport (par

exemple, modèle, variable, tâche, etc.). Commentez toutes les questions relatives à l'éthique ou à la confiance, telles que la transparence du modèle, qui peuvent être pertinentes pour la définition du problème.

Compréhension des données [10 %]
Énumérez les variables que vous avez trouvées dans le fichier fourni par l'entreprise. Pour chacun, dites s'il doit être traité comme catégorique ou numérique ; nominal, ordinal, continu ou discret ; et s'il est susceptible ou non d'être utile à la construction de la solution. Expliquez vos décisions : si vous excluez des variables à ce stade, vous pouvez justifier votre choix à l'aide de statistiques récapitulatives ou d'un histogramme de sa distribution.

Préparation des données [10 %]
Décrivez ce que vous avez fait avec les données avant le processus de modélisation. Affichez les histogrammes des données avant et après tout prétraitement que vous avez effectué. (vous n'avez pas besoin de donner des histogrammes de toutes les variables, seulement celles qui ont besoin d'être nettoyées) Si vous avez corrigé des entrées mal saisies ou corrompues dans les données, signalez ce que vous avez changé, comme les règles que vous avez utilisées ou des exemples points de données qui ont été nettoyés.

Modélisation [30 %]
Vous devez utiliser trois techniques différentes et créer des modèles avec chacune : celles-ci doivent inclure un modèle basé sur un arbre, un basé sur la régression logistique et un basé sur des réseaux de neurones. Essayez de faire en sorte que chaque modèle fonctionne aussi bien que possible : si vous avez fait varier les hyperparamètres d'un modèle, montrez quels hyperparamètres vous avez fait varier et comment cela a eu un impact sur les résultats. Décrivez comment vous divisez les données à des fins de formation, de validation et de test. Soyez méthodique et notez chaque résultat. Cette étape ressemble un peu à la recherche scientifique : vous faites des expériences dans votre recherche de la meilleure solution. Une fois que vous avez une solution, montrez comment vous avez vérifié sa robustesse. Pour les trois techniques différentes, rapportez leur capacité comparative à faire des prédictions pour ce problème, mais ne sélectionnez qu'un seul modèle pour le test final.

N'essayez pas de trouver un modèle parfait ou extrêmement précis - il n'existe pas ! Nous sommes intéressés par la procédure que vous avez suivie et la justification que vous donnez pour choisir des types/paramètres/fonctionnalités de modèle particuliers, plutôt qu'un score de précision spécifique.

Évaluation [10 %]
Analysez et décrivez le niveau de précision atteint par le modèle et les erreurs commises par votre modèle. Affichez une matrice de confusion pour votre modèle. Y a-t-il des domaines des données où les performances sont moins bonnes que dans d'autres, et y a-t-il des types d'erreurs que l'entreprise voudrait éviter plus que d'autres ? Affichez une courbe de levage ou une courbe ROC pour la capacité prédictive du modèle et expliquez ce que cela vous indique. Indiquez si l'approche de modélisation choisie et les résultats peuvent faire confiance à l'entreprise.

Approche globale et créativité [30%]
Vous devez adopter une approche structurée de l'ensemble du processus et identifier

clairement les cinq étapes CRISP-DM hors déploiement dans votre rapport. Des notes supplémentaires sont disponibles dans cette catégorie pour aller au-delà des approches de base mentionnées dans les sections ci-dessus et celles couvertes dans le cours ; par exemple, vous pouvez envisager la construction de caractéristiques ou l'ajout d'explications aux prédictions du modèle. Ceux qui font preuve (selon le système de notation commun) d'originalité et de capacités exceptionnelles d'analyse, de résolution de problèmes et/ou de créativité se verront attribuer les notes les plus élevées.

Soumission

Vous n'avez pas besoin de soumettre les modèles que vous avez construits, juste le rapport. La date limite pour ce devoir est le lundi 27 juin 2022 à 16 heures. Veuillez soumettre votre rapport via Canvas à l' adresse https://canvas.stir.ac.uk/courses/11062/assignments/88391. Vous devez l'enregistrer sous forme de fichier doc ou pdf portant le nom d'utilisateur de votre portail universitaire (3 lettres + 5 chiffres, par exemple xyz00001.pdf).

Écrivez simplement ce dont vous avez besoin pour fournir les informations requises de manière claire et concise. Vous pouvez supposer que le client a une bonne compréhension technique de l'exploration de données et
des statistiques, alors n'évitez pas les termes techniques dans votre rapport, mais là où vous les utilisez, veuillez également expliquer ce qu'ils signifient en langage clair. Pour maximiser votre note, suivez attentivement les instructions qui vous ont été données.

de système de

notation seront notées conformément au système de notation commun de troisième cycle universitaire, qui peut être trouvé ici: https://bit.ly/3sztOIt

Limite du nombre de mots

Pour les rapports qui dépassent le nombre maximal de 3 500 mots de :

- Moins de 5 % (moins de 175 mots supplémentaires), aucune note ne sera réduite. • De 5 % à 10 % (176 à 350 mots supplémentaires), la note sera réduite de cinq points de pourcentage (5 points).
- Plus de 10 % (351 mots supplémentaires ou plus), la note sera réduite de dix points de pourcentage (10 points) pour chaque tranche de 350 mots supplémentaires.
- Les pénalités de nombre de mots ne réduiront pas la note finale en dessous du seuil de réussite (50 points), donc si votre note était de 52 et que vous avez une pénalité de 5 % (5 points), votre note finale serait toujours de 50.

Remarque sur la prévention de l'inconduite académique :

Le travail qui est soumis à l'évaluation doit être votre propre travail. Tous les étudiants doivent noter que l'Université a une politique formelle sur l'intégrité académique et l'inconduite académique (y compris le plagiat) qui peut être trouvée à https://bit.ly/37fYxPw

Plagiat : nous savons que les solutions des devoirs des anciens étudiants peuvent parfois être trouvées sur GitHub ou d'autres référentiels publics. Ne soyez pas tenté d'inclure un tel code ou écrit dans votre soumission. L'utilisation d'un travail qui n'est pas le vôtre sera considérée comme une « mauvaise pratique académique » ou un « plagiat » et sera pénalisée. Pour éviter le risque que votre propre travail soit plagié par d'autres, ne partagez pas de copies de votre solution et protégez votre travail pendant et après la période d'affectation. Collusion : Il s'agit d'un travail individuel : travailler avec d'autres étudiants n'est pas autorisé. Si les étudiants soumettent le même travail ou un travail très similaire, cela sera traité comme une "collusion" et tous les étudiants impliqués seront pénalisés.

Tricherie contractuelle : demander ou payer quelqu'un d'autre pour effectuer un travail d'affectation pour vous (tricherie contractuelle) est considéré comme une faute académique grave et entraînera la fin de vos études sans récompense.

Soumissions tardives : ce devoir est soumis aux pénalités de note habituelles pour une soumission tardive. Vous pouvez envoyer des questions à ce sujet à alexander.brownlee@stir.ac.uk.